


$$H = f_{\theta_0, \Delta\theta}(X, M, P), \quad Z_j = H[j, \ell_j - 1, :], \quad \mathbf{s} = \text{cat}(\text{squeeze}_{-1}(\text{MLP}_{\phi}(Z)))$$

$$\text{selected_ids} = (\text{id}_{(1)}, \dots, \text{id}_{(k)}), \quad c_{(r)} = \text{documents}[\text{id}_{(r)}]$$



轴 $b \leq 4$: 候选微批; N : 一个 query 的全部候选; $L \leq 2048$; 首轮 $D = 1024, h = 256$ 。色块仅示意轴, 非实际维数。

对象 ■ 青: token IDs X 、0/1 padding 支持 M ; ■ 紫: 隐藏激活 E, H, Z, U, A ; ■ 橙: Head 参数 W_1, b_1, W_2, b_2 ; ■ 红: raw logits v, s ; ■ 灰: 整数位置 P 、字符串 ID / 文本列表 (不是数值张量)。

机制 M 的白格为 padding (0); 其它色块深浅仅作示意, 不对应实测值。推理无梯度、无 KV cache; 无阈值且 $\text{top_k} > 0$ 时 $k = \min(\text{top_k}, N)$, 按 ID 查原文本。